

AG × PSO × Busca Aleatória na Otimização de um Controlador Fuzzy de Rastreamento de Trajetória: Replicação Experimental de Mancilla et al. (2022)

Disciplina: Inteligência Artificial e Computacional (0700M8) — CESUPA **Trabalho:** Parte 2 — IA Evolutiva e Computação Bioinspirada · **Opção 1: Pesquisa Científica Turma:** CC5MA **Equipe (5 integrantes):** Brenda Nascimento, Cauê Jadão, Augusto Pereira, Fernando Mourão, César Ribeiro **Ampliação obrigatória (equipe de 5, Seção 5 da lauda): Comparação ampliada** — o trabalho compara duas abordagens distintas, AG × PSO (exemplo literal da lauda), estendidas com baseline de busca aleatória sob o mesmo orçamento **Pontuação extra solicitada:** Alternativa 3 — Otimização automática de parâmetros Fuzzy (comparação antes/depois na Seção 5.4) **Repositório GitHub:** <https://github.com/brenda24070071-dotcom/fuzzy-ag-path-tracking-cesupa> — Parte 2 na pasta `parte2-evolutiva/` ; Parte 1 (modelagem fuzzy) na raiz

Resumo

Este trabalho executa um protocolo experimental controlado comparando três métodos de busca — **Algoritmo Genético (AG)** real-coded, **Otimização por Enxame de Partículas (PSO)** canônico e **Busca Aleatória** uniforme (baseline) — no problema de ajuste automático dos 10 parâmetros das funções de pertinência de um controlador fuzzy Mamdani de rastreamento de trajetória, replicando o cerne do artigo-base (Mancilla et al., *Symmetry*, 2022): avaliar metaheurísticas populacionais nesse problema. Com orçamento idêntico de **220 avaliações** da função objetivo por execução e **5 execuções independentes** por método (sementes 42–46), todos os métodos reduziram o RMSE de rastreamento em 16–21% sobre a referência fixa (1,5601 m). O AG obteve a melhor média (**1,2926 m**) e o melhor resultado global (**1,2319 m**); o PSO foi o mais estável (desvio-padrão 0,0156); e a busca aleatória ficou surpreendentemente competitiva (média 1,3208 m) — um resultado honesto que discutimos criticamente em termos de orçamento de busca, dimensionalidade e geometria da paisagem de fitness.

1. Problema e abordagem escolhida

Abordagem (Opção 1): replicação experimental adaptada de artigo científico recente, com protocolo próprio de comparação contra baseline.

Problema concreto: controladores fuzzy dependem fortemente da forma e posição das funções de pertinência (MFs). O ajuste manual é trabalhoso e subótimo. O artigo-base formula o ajuste como **problema de otimização contínua** resolvido por metaheurísticas populacionais, avaliando cada candidato por simulação de um robô que segue pistas de referência. Nós replicamos essa formulação

e acrescentamos um baseline de busca aleatória — exigência metodológica clássica para verificar se a “inteligência” do método agrega valor sobre amostragem pura com o mesmo custo.

1.1 Formulação como busca/otimização

Elemento	Definição
Variáveis de decisão	$p = (p_0, \dots, p_9) \in [0,1]^{10}$ — parâmetros que definem larguras, centros e rampas das MFs das duas entradas do controlador (5 por variável)
Espaço de busca	Hipercubo contínuo $[0,1]^{10}$ (parâmetros normalizados; desnormalização interna por escalas fixas)
Função objetivo	$f(p)$ = média do RMSE do erro lateral nas 3 pistas (M, A, S) — minimização
Restrições	Caixa $[0,1]^{10}$, imposta por <i>clipping</i> nos três métodos
Factibilidade	Penalidade de +2000 quando o robô não completa a pista em $T_{MAX} = 50$ s; 5000 quando a inferência fuzzy falha (cobertura nula) — soluções inviáveis são fortemente desfavorecidas, sem descarte
Métricas	Melhor/pior/média/desvio-padrão do fitness final (5 sementes); curva de convergência por avaliação; tempo médio; n° de avaliações

2. Artigo-base e justificativa

Referência completa: MANCILLA, A.; GARCÍA-VALDEZ, M.; CASTILLO, O.; MERELO-GUERVÓS, J. J. Optimal Fuzzy Controller Design for Autonomous Robot Path Tracking Using Population-Based Metaheuristics. *Symmetry*, v. 14, n. 2, art. 202, 2022. DOI: 10.3390/sym14020202.

Justificativa da escolha: (i) publicado em **2022** — dentro da janela de 7 anos exigida; (ii) periódico indexado (MDPI *Symmetry*, Scopus/JCR); (iii) metodologia clara e replicável no escopo da disciplina: descreve o modelo cinemático, as pistas (pontos de controle + spline), a estrutura do controlador (2 entradas $\times$ 5 termos, 25 regras Mamdani) e a função objetivo (RMSE); (iv) o tema central do artigo — **comparar metaheurísticas populacionais** no ajuste de MFs — é exatamente o objeto desta Parte 2; (v) continuidade com a Parte 1 do trabalho, que reproduziu a modelagem fuzzy do mesmo artigo (lá o foco era o sistema fuzzy; aqui é o experimento evolutivo).

Leitura técnica (síntese): problema = rastreamento de trajetória; objetivo = minimizar erro lateral; variáveis de decisão = parâmetros das MFs de entrada; representação = vetor real; aptidão = RMSE médio em múltiplas pistas; operadores = os de cada metaheurística; protocolo = múltiplas execuções independentes por método; limitação = resultados dependentes de orçamento e implementação.

3. Algoritmos implementados

3.1 Algoritmo Genético (AG) real-coded

Componente	Escolha
Representação	Vetor real de 10 genes em $[0, 1]$
População	20 indivíduos, inicialização uniforme
Seleção	Torneio de 3
Cruzamento	Aritmético por gene ($c1 = \alpha \cdot p1 + (1-\alpha) \cdot p2$, $\alpha \sim U(0,1)$ por gene), taxa 0,7
Mutação	Gaussiana ($\sigma = 0,2$), taxa 0,3 por gene, com <i>clip</i> em $[0, 1]$
Elitismo	2 melhores preservados por geração
Parada	10 gerações (orçamento: $20 + 10 \times 20 = 220$ avaliações)

É o mesmo AG da Parte 1 (mesmo código e parâmetros), o que permite verificação cruzada: as 5 execuções reproduzem aqui exatamente os mesmos valores finais obtidos lá.

3.2 PSO (global best) canônico

Componente	Escolha
Enxame	20 partículas; posições $U(0,1)^{10}$; velocidades $U(-0,1, 0,1)$
Atualização	$v \leftarrow w \cdot v + c1 \cdot r1 \cdot (pbest - x) + c2 \cdot r2 \cdot (gbest - x)$; $x \leftarrow x + v$
Coeficientes	$w = 0,7298$; $c1 = c2 = 1,49618$ (valores de constrição de Clerc–Kennedy)
Limites	Velocidade limitada a $ v \leq 0,5$; posição confinada em $[0, 1]$ por <i>clip</i>
Parada	10 iterações (orçamento: $20 + 10 \times 20 = 220$ avaliações)

3.3 Busca Aleatória (baseline)

220 amostras i.i.d. uniformes em $[0, 1]^{10}$, guardando a melhor. Mesmo orçamento dos demais — qualquer vantagem das metaheurísticas deve aparecer *acima* desse piso.

4. Metodologia experimental

- **5 execuções independentes por método**, sementes fixas **42–46** (exigência da lauda para métodos estocásticos; garante reprodutibilidade exata).
- **Orçamento idêntico**: 220 avaliações da função objetivo por execução, contadas por um invólucro (`AvaliadorFitness`) que também registra a curva de melhor-até-agora por avaliação — comparação justa por custo, não por “geração”.
- **Mesma função objetivo** para todos: simulação determinística do robô (passo de Euler 0,1 s) nas mesmas 3 pistas.
- **Referência fixa (antes da otimização)**: controlador com todos os genes em 0,5 — RMSE = **1,5601 m**.

- **Ambiente:** Python 3.14, NumPy 2.4.6, SciPy 1.17.1, Matplotlib 3.10.9, Windows 11; tempo total do experimento $\approx$ **1,3 min.**

5. Resultados

5.1 Tabela-resumo (RMSE final em metros, 5 sementes por método)

Método	Melhor	Pior	Média	Desv. padrão	Tempo médio/execução	Avaliações
AG	1,2319	1,3193	1,2926	0,0354	6,0 s	220
PSO	1,2966	1,3349	1,3126	0,0156	5,9 s	220
Busca Aleatória	1,2866	1,3487	1,3208	0,0246	3,0 s	220
Referência fixa	1,5601	—	—	—	—	1

Resultados por execução em `resultados/estatisticas_execucoes.csv` ; melhores vetores de genes em `resultados/melhores_individuos.json` .

5.2 Convergência

`resultados/convergencia_metodos.png` mostra o melhor fitness até a n-ésima avaliação (média e faixa min–max das 5 sementes). Leitura: (i) todos os métodos encontram soluções factíveis (que completam as 3 pistas) nas primeiras ~10 avaliações; (ii) o grosso do ganho ocorre até ~60 avaliações; (iii) depois disso o AG segue melhorando lentamente (mutação + elitismo), o PSO estabiliza cedo (convergência do enxame para o gbest) e a busca aleatória melhora apenas por sorte decrescente — padrão coerente com a teoria.

5.3 Estabilidade

Boxplot em `resultados/boxplot_metodos.png` . O PSO apresentou a menor variância entre sementes (0,0156) — o enxame converge consistentemente para soluções de qualidade semelhante. O AG tem variância maior, porém com cauda *boa*: foi o único a atingir 1,2319 (semente 44). A busca aleatória varia mais e tem a pior média, como esperado.

5.4 Antes × depois (pontuação extra — Alternativa 3)

A otimização automática de parâmetros fuzzy reduziu o RMSE de **1,5601 m** $\rightarrow$ **1,2319 m** (**–21,0%**) na melhor solução global (AG, semente 44). As trajetórias antes/depois nas 3 pistas estão em `resultados/antes_depois_trajetorias.png` — visivelmente menos sobressinal nas curvas fechadas. A leitura dos genes otimizados (zona morta angular alargada de 0,5 para 0,83; termos médios do erro lateral estreitados) está documentada na Parte 1 (`docs/funcoes_de_pertinencia.md` daquele repositório).

5.5 Custo computacional

AG e PSO: ≈ 6 s por execução (220 avaliações + sobrecarga dos operadores, desprezível frente ao custo da simulação). Busca aleatória: ≈ 3 s — *mais rápida por avaliação* porque amostras aleatórias ruins frequentemente divergem cedo ou falham na inferência, encerrando a simulação antes; já AG/PSO concentram avaliações em controladores bons, que completam as pistas inteiras (mais passos simulados por avaliação). O custo é dominado pelo número de passos de simulação, não pelos operadores dos métodos.

6. Análise crítica e comparação

Semelhanças com o artigo-base: replicamos a tendência central reportada — metaheurísticas populacionais ajustam MFs com ganho consistente sobre a configuração não otimizada (−16% a −21% de RMSE), com AG e PSO chegando a soluções de qualidade comparável entre si.

Diferenças e causas prováveis de divergência: não comparamos valores absolutos de RMSE com o artigo porque (i) nosso orçamento é deliberadamente pequeno (220 avaliações contra populações/iterações maiores no artigo); (ii) detalhes de implementação diferem (integração de Euler, critério de chegada, discretização do centroide, convenção de sinais documentada na Parte 1); (iii) o artigo avalia mais metaheurísticas e variantes. Com orçamentos diferentes, comparação absoluta seria metodologicamente inválida — por isso ancoramos a comparação no baseline interno (busca aleatória e referência fixa).

O achado mais interessante (e honesto): a busca aleatória ficou a apenas $\sim 2\%$ da média do AG. Três fatores explicam: (1) **orçamento pequeno** — 220 avaliações dão às metaheurísticas pouco tempo para explorar e explorar; (2) **paisagem benigna na região central** — a parametrização $[0,1]^{10}$ foi desenhada (no artigo-base) para que qualquer ponto razoável gere um controlador funcional; amostras uniformes caem com frequência em bacias boas; (3) **dimensionalidade moderada** (10-D). A vantagem das metaheurísticas aparece na *cauda da qualidade*: nenhuma execução da busca aleatória alcançou o 1,2319 do AG, e a média do AG é a melhor com significância prática. Lição metodológica: **sem o baseline de busca aleatória, seria fácil superestimar o mérito dos métodos** — exatamente o motivo de a lauda exigir comparação.

AG $\times$ PSO: o AG explorou melhor (mutação gaussiana mantém diversidade; elitismo protege o melhor), enquanto o PSO explotou mais rápido e estagnou (todas as partículas atraídas para o gbest em 10 iterações). Com orçamento maior, espera-se o PSO recuperar terreno — hipótese verificável em trabalho futuro.

Limitações do experimento: orçamento pequeno (decisão consciente para viabilizar 15 execuções completas no escopo da disciplina); 5 sementes permitem estatística descritiva, mas não testes de hipótese robustos (n pequeno); apenas três métodos (o artigo-base inclui outros); função objetivo determinística dada a semente (sem ruído de medição).

7. Conclusão

O protocolo experimental comparou AG, PSO e busca aleatória sob orçamento idêntico no ajuste de parâmetros de um controlador fuzzy de rastreamento, replicando o núcleo metodológico de Mancilla et al. (2022). O AG apresentou a melhor média (1,2926 m) e o melhor resultado global (1,2319 m; -21,0% sobre a referência fixa), o PSO a maior estabilidade, e o baseline aleatório revelou que, neste orçamento e paisagem, parte do ganho vem da amostragem em si — análise crítica que consideramos o principal aprendizado científico do trabalho. Trabalhos futuros: orçamentos maiores, mais sementes com teste estatístico (Wilcoxon), DE e variantes de PSO com reinicialização, e co-otimização das MFs de saída.

Contribuições dos integrantes

Todos os integrantes revisaram o código e os documentos e estão preparados para a arguição.

Integrante	Contribuição principal nesta Parte 2
Brenda Nascimento	Formulação do problema de otimização e gestão do repositório
Cauê Jadão	Núcleo de simulação/fitness (compartilhado com a Parte 1) e validação das execuções
Augusto Pereira	Implementação do AG e do PSO; protocolo experimental
Fernando Mourão	Execução dos experimentos, métricas, gráficos e CSV de evidências
César Ribeiro	Relatório técnico, análise crítica e slides

Declaração de uso de IA

A equipe utilizou IA agêntica (Claude Code, Anthropic) para implementação do script experimental (reutilizando o núcleo validado na Parte 1), rascunho da documentação e revisão de coerência. Todo o material foi revisado, executado e validado pelos integrantes, que assumem integral responsabilidade pelo conteúdo. Declaração completa: `docs/declaracao_uso_ia.md`.

Referências

[1] MANCILLA, A.; GARCÍA-VALDEZ, M.; CASTILLO, O.; MERELO-GUERVÓS, J. J. Optimal Fuzzy Controller Design for Autonomous Robot Path Tracking Using Population-Based Metaheuristics. *Symmetry*, v. 14, n. 2, art. 202, 2022. DOI: 10.3390/sym14020202.

[2] HOLLAND, J. H. *Adaptation in Natural and Artificial Systems*. Ann Arbor: University of Michigan Press, 1975.

[3] KENNEDY, J.; EBERHART, R. Particle swarm optimization. In: *Proceedings of the IEEE International Conference on Neural Networks*, Perth, 1995. p. 1942–1948.

[4] CLERC, M.; KENNEDY, J. The particle swarm — explosion, stability, and convergence in a multidimensional complex space. *IEEE Transactions on Evolutionary Computation*, v. 6, n. 1, p. 58–

73, 2002.

[5] CORDÓN, O.; HERRERA, F.; HOFFMANN, F.; MAGDALENA, L. *Genetic Fuzzy Systems: Evolutionary Tuning and Learning of Fuzzy Knowledge Bases*. Singapore: World Scientific, 2001.

[6] BERGSTRA, J.; BENGIO, Y. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, v. 13, p. 281–305, 2012.

[7] MAMDANI, E. H.; ASSILIAN, S. An experiment in linguistic synthesis with a fuzzy logic controller. *International Journal of Man-Machine Studies*, v. 7, n. 1, p. 1–13, 1975.

Ferramentas: Python, NumPy, SciPy, Matplotlib, Git/GitHub.