

AG × PSO × Busca Aleatória na Otimização de um Controlador Fuzzy de Rastreamento de Trajetória

Parte 2 — IA Evolutiva e Computação Bioinspirada · Opção 1: Pesquisa Científica

Replicação experimental de Mancilla et al., *Symmetry* 2022, 14, 202

Inteligência Artificial e Computacional (0700M8) — CESUPA · Prof. Daniel Leal Souza

Turma: CC5MA · Equipe (5 integrantes): Brenda Nascimento, Cauê Jadão, Augusto Pereira, Fernando Mourão, César Ribeiro

Ampliação obrigatória (equipe de 5): Comparação ampliada — AG × PSO (+ baseline de busca aleatória)

Repositório: github.com/brenda24070071-dotcom/fuzzy-ag-path-tracking-cesupa — Parte 2 na pasta parte2-evolutiva/ (Parte 1 na raiz)

Contexto: artigo-base e objetivo

Artigo-base (2022, indexado — dentro da janela de 7 anos): Mancilla, García-Valdez, Castillo & Merelo-Guervós. *Optimal Fuzzy Controller Design for Autonomous Robot Path Tracking Using Population-Based Metaheuristics*. Symmetry 14(2), 202. DOI 10.3390/sym14020202.

- Controladores fuzzy dependem da forma/posição das **funções de pertinência** — ajuste manual é caro e subótimo;
- O artigo formula o ajuste como **otimização contínua** resolvida por **metaheurísticas populacionais**, avaliadas por simulação de rastreamento;
- **Nosso objetivo:** replicar o cerne do experimento — comparar **AG × PSO** — e acrescentar o baseline metodológico de **Busca Aleatória** com o mesmo orçamento;
- **Continuidade:** a modelagem fuzzy (25 regras, MFs, inferência Mamdani) foi reproduzida e validada na Parte 1 deste trabalho; aqui o foco é o **experimento evolutivo**.

Justificativa da escolha: metodologia clara e replicável; problema realista de robótica; une as duas partes da disciplina.

Formulação como problema de busca/otimização

Elemento	Definição
Variáveis de decisão	$p \in [0,1]^{10}$ — larguras, centros e rampas das MFs das 2 entradas do controlador (5 parâmetros por variável)
Espaço de busca	Hipercubo contínuo $[0,1]^{10}$ (parâmetros normalizados)
Função objetivo	RMSE médio do erro lateral em 3 pistas (M, A, S) — minimização
Restrições	Caixa $[0,1]^{10}$ imposta por <i>clip</i> nos três métodos
Factibilidade	Penalidade +2000 se o robô não completa a pista; 5000 se a inferência falha
Métricas	Melhor / pior / média / desvio-padrão (5 sementes); convergência por avaliação; tempo; nº de avaliações

Avaliação de um candidato: constrói o controlador Mamdani com os 10 parâmetros → simula o robô (cinemática de bicicleta, Euler 0,1 s) nas 3 pistas → RMSE médio do erro lateral.

Algoritmos: AG real-coded

Componente	Escolha
Representação	vetor real, 10 genes em [0,1]
População	20 (inicialização uniforme)
Seleção	torneio de 3
Cruzamento	aritmético por gene, taxa 0,7
Mutação	gaussiana $\sigma=0,2$, taxa 0,3/gene
Elitismo	2 melhores preservados
Parada	10 gerações = 220 avaliações

- É o mesmo **AG da Parte 1** (mesmo código e parâmetros);
- Verificação cruzada: com as mesmas sementes, reproduz aqui **exatamente** os mesmos resultados finais da Parte 1 (ex.: semente 44 → 1,2319 m);
- Mutação gaussiana + elitismo mantêm **diversidade com proteção do melhor** — relevante na análise dos resultados.

Algoritmos: PSO canônico e baseline aleatório

PSO (global best)

$$v \leftarrow w \cdot v + c1 \cdot r1 \cdot (pbest - x) + c2 \cdot r2 \cdot (gbest - x)$$
$$x \leftarrow \text{clip}(x + v, 0, 1)$$

Componente	Escolha
Enxame	20 partículas
Coeficientes	$w=0,7298$; $c1=c2=1,49618$ (construção de Clerc–Kennedy)
Limites	$ v \leq 0,5$; posição em $[0,1]$
Parada	10 iterações = 220 avaliações

Busca Aleatória (baseline)

- 220 amostras i.i.d. uniformes em $[0,1]^{10}$, guardando a melhor;
- **Mesmo orçamento** dos demais métodos;
- Papel metodológico: qualquer vantagem das metaheurísticas deve aparecer **acima desse piso** — sem ele, é fácil superestimar o mérito dos métodos.

Protocolo experimental


- **5 execuções independentes por método**, sementes fixas **42–46** (lauda: ≥ 5 para métodos estocásticos) → resultados **exatamente reproduzíveis**;
- **Orçamento idêntico**: 220 avaliações da função objetivo por execução, contadas por um invólucro (`AvaliadorFitness`) que registra a curva de melhor-até-agora **por avaliação** — comparação justa por custo, não por "geração";
- **Mesma função objetivo** (determinística dada a semente) e mesmas 3 pistas para todos;
- **Referência fixa (antes)**: genes = 0,5 → RMSE = **1,5601 m**;
- **Ambiente**: Python 3.14, NumPy 2.4.6, SciPy 1.17.1; tempo total $\approx 1,3$ min (15 execuções);
- **Evidências**: CSV por execução, JSON com melhores indivíduos, gráficos em `resultados/`.

Resultados: tabela-resumo (RMSE em metros)

Método	Melhor	Pior	Média	Desv. padrão	Tempo médio	Avaliações
AG	1,2319	1,3193	1,2926	0,0354	6,0 s	220
PSO	1,2966	1,3349	1,3126	0,0156	5,9 s	220
Busca Aleatória	1,2866	1,3487	1,3208	0,0246	3,0 s	220
Referência fixa	1,5601	—	—	—	—	1


- Todos os métodos melhoram **16–21%** sobre a referência fixa;
- **AG**: melhor média e melhor solução global (1,2319, semente 44);
- **PSO**: mais estável (menor desvio-padrão entre sementes);
- **Busca aleatória mais rápida por execução**: amostras ruins divergem/falham cedo e encerram a simulação antes — o custo é dominado pelos passos simulados, não pelos operadores.

Curvas de convergência (por avaliação, 5 sementes)




Soluções factíveis surgem nas primeiras ~10 avaliações; o grosso do ganho até ~60; depois o **AG segue melhorando** (mutação + elitismo), o **PSO estagna** (enxame converge ao gbest) e a busca aleatória depende de sorte decrescente.

Estabilidade e antes/depois (extra — Alternativa 3)



PSO: menor variância. AG: cauda boa (único a atingir 1,2319).



Otimização automática de parâmetros fuzzy: **1,5601** → **1,2319 m**
(-21,0%), menos sobressinal nas curvas.

Análise crítica

Achado mais interessante (e honesto): a busca aleatória ficou a ~2% da média do AG. Causas: orçamento pequeno (220 avaliações), paisagem benigna na região central da parametrização e dimensionalidade moderada (10-D). A vantagem das metaheurísticas aparece na **cauda da qualidade**: nenhuma execução aleatória alcançou o 1,2319 do AG.

- **AG × PSO:** AG explora melhor (diversidade por mutação + elitismo); PSO explota rápido e estagna em 10 iterações — com orçamento maior, a hipótese é que o PSO recupere terreno;
- **Comparação com o artigo-base:** replicamos a **tendência** (metaheurísticas populacionais ajustam MFs com ganho consistente); não comparamos RMSE absoluto — orçamentos e detalhes de implementação diferem (causas de divergência declaradas no relatório);
- **Limitações:** 5 sementes (estatística descritiva, sem teste de hipótese), 3 métodos, orçamento deliberadamente pequeno para viabilizar 15 execuções no escopo da disciplina.

Conclusão, IA e referências

- Protocolo controlado (orçamento idêntico, 5 sementes, baseline) comparando AG, PSO e busca aleatória no ajuste de MFs fuzzy;
- **AG**: melhor média (1,2926 m) e melhor global (**1,2319 m, -21,0%**); **PSO**: mais estável; **baseline** revelou o papel do orçamento e da paisagem — principal aprendizado científico;
- Trabalhos futuros: orçamentos maiores, teste de Wilcoxon com mais sementes, DE e variantes de PSO, co-otimização das MFs de saída.

Uso de IA (declarado)

Claude Code (Anthropic): implementação do script experimental (núcleo reaproveitado da Parte 1), rascunhos de documentação e revisão de coerência. Tudo revisado, executado e validado pela equipe — `docs/declaracao_uso_ia.md`.

Referências principais

[1] Mancilla et al., Symmetry 14(2):202, 2022 · [2] Holland, 1975 · [3] Kennedy & Eberhart, ICNN 1995 · [4] Clerc & Kennedy, IEEE TEC 6(1), 2002 · [5] Cordón et al., Genetic Fuzzy Systems, 2001 · [6] Bergstra & Bengio, JMLR 13, 2012 · [7] Mamdani & Assilian, IJMMMS 7(1), 1975

Obrigado!