

Controle Fuzzy Mamdani Otimizado por Algoritmo Genético para Rastreamento de Trajetória de Robô Autônomo

Reprodução (A1) de Mancilla et al., *Symmetry* 2022, 14, 202 — com extensão de otimização por AG

Inteligência Artificial e Computacional (0700M8) — CESUPA · Prof. Daniel Leal Souza

Turma: CC5MA · Equipe (5 integrantes): Brenda Nascimento, Cauê Jadão, Augusto Pereira, Fernando Mourão, César Ribeiro

Trilha de ampliação (equipe de 5): Comparação de modelos — Mamdani × TSK experimental (+ baseline × otimizado)

github.com/brenda24070071-dotcom/fuzzy-ag-path-tracking-cesupa

O problema: rastreamento de trajetória

- Robô autônomo (cinemática de **bicicleta**, $L = 2,5$ m, $v = 3,33$ m/s) deve **seguir uma pista de referência** com o menor desvio possível;
- Controlador decide a **taxa de guinada** ω a partir de dois erros medidos;
- Aplicações: veículos autônomos, AGVs, máquinas agrícolas.

Por que lógica fuzzy?

- Conhecimento de condução é **linguístico**: "um pouco à direita $\rightarrow$ vire de leve à esquerda";
- Fronteiras entre situações são **graduais**, não nítidas;
- Tolerância a imprecisão de modelo — sem exigir solução analítica exata.

Variáveis do controlador

Variável	Papel	Unidade	Sinal positivo =
e_lat	entrada	m	robô à direita da pista
theta_e	entrada	rad	apontando à esquerda
omega	saída	rad/s	guinada à esquerda

5 termos linguísticos por variável: **AN, MN, Z, MP, AP**
Universo de discurso: $[-50, 50]$; região fina de operação: $[-5, 5]$.

Artigo de referência e levantamento bibliográfico

Artigo principal: Mancilla, García-Valdez, Castillo & Merelo-Guervós (2022). *Optimal Fuzzy Controller Design for Autonomous Robot Path Tracking Using Population-Based Metaheuristics*. Symmetry 14(2), 202. DOI 10.3390/sym14020202

- **Bases consultadas:** Google Scholar, IEEE Xplore, MDPI, ScienceDirect/SpringerLink;
- **Palavras-chave:** "fuzzy logic controller" + "path tracking"; "fuzzy controller" + "genetic algorithm"; "genetic fuzzy systems";
- **Inclusão:** revisão por pares, estrutura fuzzy descrita (reprodutível), aplicação em robótica móvel ou fundamento;
Exclusão: sem detalhe do modelo, fora de escopo (tipo-2, deep learning), sem acesso;
- **7 trabalhos relacionados** tabelados (Mamdani 1975; Takagi-Sugeno 1985; Zadeh 1965; Antonelli et al. 2007; Cordon et al. 2001; Precup & Hellendoorn 2011) — ver `docs/trabalhos_relacionados.md`.

Por que este artigo? Reprodutível (modelo + pistas + controlador + fitness descritos), recente e de acesso aberto, e une controle fuzzy + computação evolutiva — as duas frentes da disciplina.

Metodologia: simulação e função objetivo

Modelo cinemático (Euler, $\Delta t = 0,1$ s)

$$x^+ = x + v \cdot \cos\theta \cdot \Delta t$$

$$y^+ = y + v \cdot \sin\theta \cdot \Delta t$$

$$\theta^+ = \theta + (v/L) \cdot \tan\delta \cdot \Delta t, \quad \delta = \arctan(L \cdot \omega / v), \quad |\delta| \leq 45^\circ$$

Pistas de referência

- 3 pistas (M, A, S) por **spline cúbica** sobre pontos de controle do artigo;
- Ponto mais próximo via k-d tree → erros `e_lat` (produto vetorial) e `theta_e` (normalizado em $[-\pi, \pi]$).

Função objetivo (fitness)


- **RMSE do erro lateral**, média nas 3 pistas;
- Término: chegada ao fim da pista (raio 2 m) ou $T_{MAX} = 50$ s;
- Penalidades: **+2000** se não completa o percurso; 5000 se a inferência falha;
- → a penalidade força o AG a só refinar controladores *válidos*.

Modelagem fuzzy: funções de pertinência

- **Triangulares** no centro (Z, MN, MP) e **trapezoidais** nas pontas (AN, AP — ombros até ± 50 garantem cobertura);
- MFs das **entradas**: parametrizadas por **10 genes** $p \in [0,1]^{10}$ (larguras, centros e rampas);
- MFs da **saída**: fixas — preserva o significado físico da ação e reduz o espaço de busca;
- Limites dos genes impedem degeneração (sem colapso de suporte nem sobreposição total).

Fórmulas e tabelas completas:

`docs/funcoes_de_pertinencia.md`



MFs após otimização pelo AG (erro angular, erro lateral e saída ω)

Base de regras: 25 regras (5×5), antissimétrica

$\theta_e \setminus e_{lat}$	AN (muito à esq.)	MN	Z	MP	AP (muito à dir.)
AN (apont. muito à dir.)	Z	MP	AP	AP	AP
MN	Z	MP	MP	MP	MP
Z (alinhado)	AN	Z	Z	Z	AP
MP	MN	MN	MN	MN	Z
AP (apont. muito à esq.)	AN	AN	AN	MN	Z

- **Correção de rumo:** alinhado em posição, erro angular → ação oposta ao erro;
- **Retorno à pista:** alinhado mas afastado → guinada forte em direção à pista;
- **Zona morta:** desvios pequenos não geram ação (evita chattering);
- **Convergência:** afastado mas já apontando de volta → $\omega = Z$ (evita sobressinal);
- **Conflito:** afastado e apontando para fora → correção máxima;
- Estrutura **antissimétrica** = simetria física do problema.

Inferência Mamdani e implementação

Pipeline de inferência

- **Fuzzificação:** singleton nas duas entradas;
- **Operador E:** mínimo (t-norma);
- **Implicação:** mínimo (trunca o consequente);
- **Agregação:** máximo sobre as 25 regras;
- **Defuzzificação:** **centroide** do conjunto agregado.

Arquitetura do código

- `FastFuzzyController` : motor Mamdani em NumPy (~1500× mais rápido) — usado no laço do AG;
- `build_fuzzy` : mesmo sistema em **scikit-fuzzy** — cenários, superfície e gráficos (validação cruzada);
- AG real-coded: torneio $k=3$, cruzamento aritmético (0,7), mutação gaussiana (0,3; $\sigma=0,2$), elitismo 2;
- 5 execuções independentes, sementes 42–46 → **reprodutível**.

Cenários de teste (valores reais do sistema)


Caso	e_lat	theta_e	ω baseline	ω otimizado	Interpretação
Nulo	0	0	0,000	0,000	equilíbrio exato ✓
Lateral alto (dir.)	+5	0	+17,279	+17,032	vira à esquerda, de volta à pista ✓
Lateral alto (esq.)	-5	0	-17,279	-17,032	antissimétrico ✓
Angular alto	0	+2	-17,279	-17,271	corrige o rumo ✓
Aproximação (fronteiriço)	+5	+2	0,000	0,000	já convergindo → não interfere ✓
Conflito crítico	-5	+2	-17,279	-17,279	divergindo → ação máxima ✓

$|\omega| = 17,3$ corresponde ao centroide dos conjuntos AN/AP; na prática satura o esterçamento em $\pm 45^\circ$. Tabela completa com análise de coerência: `docs/cenarios_de_teste.md`.

Resultados: rastreamento e efeito do AG

Pista	RMSE base (m)	RMSE otim. (m)	Δ
M	0,802	0,705	-12%
A	2,231	2,044	-8%
S	1,647	0,947	-42%
Média	1,560	1,232	-21,0%

- Robô **completa as 3 pistas** nos dois casos;
- 5 execuções do AG convergem para 1,23–1,32 m → robustez à semente.



Análise crítica (1): defeito encontrado e corrigido

Versão inicial: matriz de regras **espelhada** no eixo do erro lateral em relação à convenção de sinal do simulador → realimentação lateral *positiva*: o robô seguia a pista por alguns metros e **divergia** (RMSE $\approx$ 2085 m, com penalidade). Segundo problema: sem critério de chegada, o robô completava a pista em $\sim$ 14 s e vagava até os 50 s, disparando a penalidade mesmo rastreando bem.

Correções validadas: espelhamento das colunas da matriz + detecção de chegada. RMSE baseline: 2085 → **1,56 m**; melhoria do AG: 0,5% → **21,0%**.

- **Lição 1:** convenções de sinal são parte da modelagem fuzzy — documentamos todas (`docs/base_de_regras.md`);
- **Lição 2:** validação de **malha fechada** é indispensável: cenários pontuais isolados não revelavam o problema;
- **Lição 3:** a penalidade de não-chegada na fitness detecta corretamente controladores inválidos.

Análise crítica (2): limites, sensibilidade e Mamdani × TSK

Onde funciona bem / onde sofre

- Retas e curvas suaves: erro < 1 m, captura sem oscilação;
- Curvas fechadas: laços de recaptura (v fixa, sem antecipação de curvatura) — pior caso: pista A;

Parâmetros sensíveis

- Zona morta lateral: estreita → chattering; larga → erro de regime;
- Ombro AN/AP angular: AG o reduziu (1,25→0,79) e compensou alargando a zona morta angular (0,5→0,83).

Mamdani × TSK (experimental — trilha de ampliação)

- TSK ordem zero: mesmas regras, consequentes constantes, média ponderada;
- Baseline: **TSK melhor** (1,43 × 1,56 m) — saída mais suave;
- Parâmetros otimizados p/ Mamdani: TSK **falha a chegada na pista A** → o ajuste do AG é específico do motor (co-adaptação);
- **Mamdani**: saída linguística → base auditável.

Melhorias futuras

- 3ª entrada: curvatura da pista (antecipação); velocidade variável;
- Otimizar MFs de saída; comparar AG × PSO × Mamdani × TSK.

Conclusão, IA e referências

- Reprodução mínima viável **funcional e reprodutível** do controlador de Mancilla et al. (2022): Mamdani 5×5, 25 regras, centroide;
- AG real-coded reduziu o RMSE médio de **1,56 m** → **1,23 m (-21%)** ajustando só as MFs de entrada;
- Ciclo completo: modelagem justificada → implementação → validação experimental → análise crítica honesta.

Uso de IA (declarado)

Claude Code (Anthropic): esboço de código, revisão/depuração (identificou os 2 defeitos, validados pela equipe por simulação) e rascunhos de documentação. Tudo revisado, executado e validado pelos integrantes — `docs/declaracao_uso_ia.md`.

Referências principais

[1] Mancilla et al., Symmetry 14(2):202, 2022 · [2] Antonelli et al., IEEE TFS 15(2), 2007 · [3] Mamdani & Assilian, IJMMS 7(1), 1975 · [4] Takagi & Sugeno, IEEE SMC-15(1), 1985 · [5] Cordón et al., Genetic Fuzzy Systems, 2001 · [6] Precup & Hellendoorn, Comput. Ind. 62(3), 2011 · [7] Zadeh, Inf. & Control 8(3), 1965

github.com/brenda24070071-dotcom/fuzzy-ag-path-tracking-cesupa — Obrigado!